Валидация методов отбора данных, основанных на геометрических свойствах внутренних представлений

Студент: Анастасия Линич
Куратор: Егор Швецов

Школа Анализа Данных

Апрель 2026 г.

Цель

Исследовать методы отбора данных для обучения языковых моделей, основанные на геометрических свойствах внутренних представлений, и проверить гипотезу о том, что такие метрики, как внутренняя размерность (Intrinsic Dimensionality) и Effective Rank, позволяют находить более информативные примеры.

Intrinsic Dimensionality (MLE)

Оценка внутренней размерности по расстояниям до ближайших соседей:

$$\hat{d} = \left(\frac{1}{k-1} \sum_{i=1}^{k-1} \log \frac{T_k}{T_i} \right)^{-1}$$

где:

T_i — расстояние до i-го ближайшего соседа,

T_k — расстояние до k-го соседа.

Correlation Dimension (CorrInt)

Корреляционный интеграл:

$$C(\varepsilon) = \frac{2}{n(n-1)} \sum_{i<j} \mathbb{I}(\|x_i - x_j\| < \varepsilon)$$

Оценка размерности:

$$d = \lim_{\varepsilon \to 0} \frac{\log C(\varepsilon)}{\log \varepsilon}$$

TwoNN

Отношение расстояний до ближайших соседей:

$$\mu_i = \frac{T_{2,i}}{T_{1,i}}$$

Оценка размерности:

$$d = \left(\frac{1}{n} \sum_{i=1}^{n} \log \mu_i \right)^{-1}$$

где:

$T_{1,i}$, $T_{2,i}$ — расстояния до ближайших соседей.

Effective Rank

Нормировка сингулярных значений:

$$p_i = \frac{\sigma_i}{\sum_j \sigma_j}$$

Эффективный ранг:

$$r_{\text{eff}} = \exp\left(-\sum_i p_i \log p_i\right)$$

где:

σ_i — сингулярные значения.

Schatten Norm

Определение нормы:

$$\|X\|_p = \left(\sum_i \sigma_i^p \right)^{1/p}$$

где:

σ_i — сингулярные значения,

p — параметр.

Результаты

Full Data (100%): **3.26**

	Random	CorrInt	MLE	TwoNN	effective_rank
10%	**4.14**	4.25	4.37	4.22	4.20
30%	**3.73**	3.79	3.74	3.77	3.76
50%	**3.44**	3.48	3.45	3.46	3.46
70%	**3.31**	3.34	3.31	3.32	3.32

Результаты

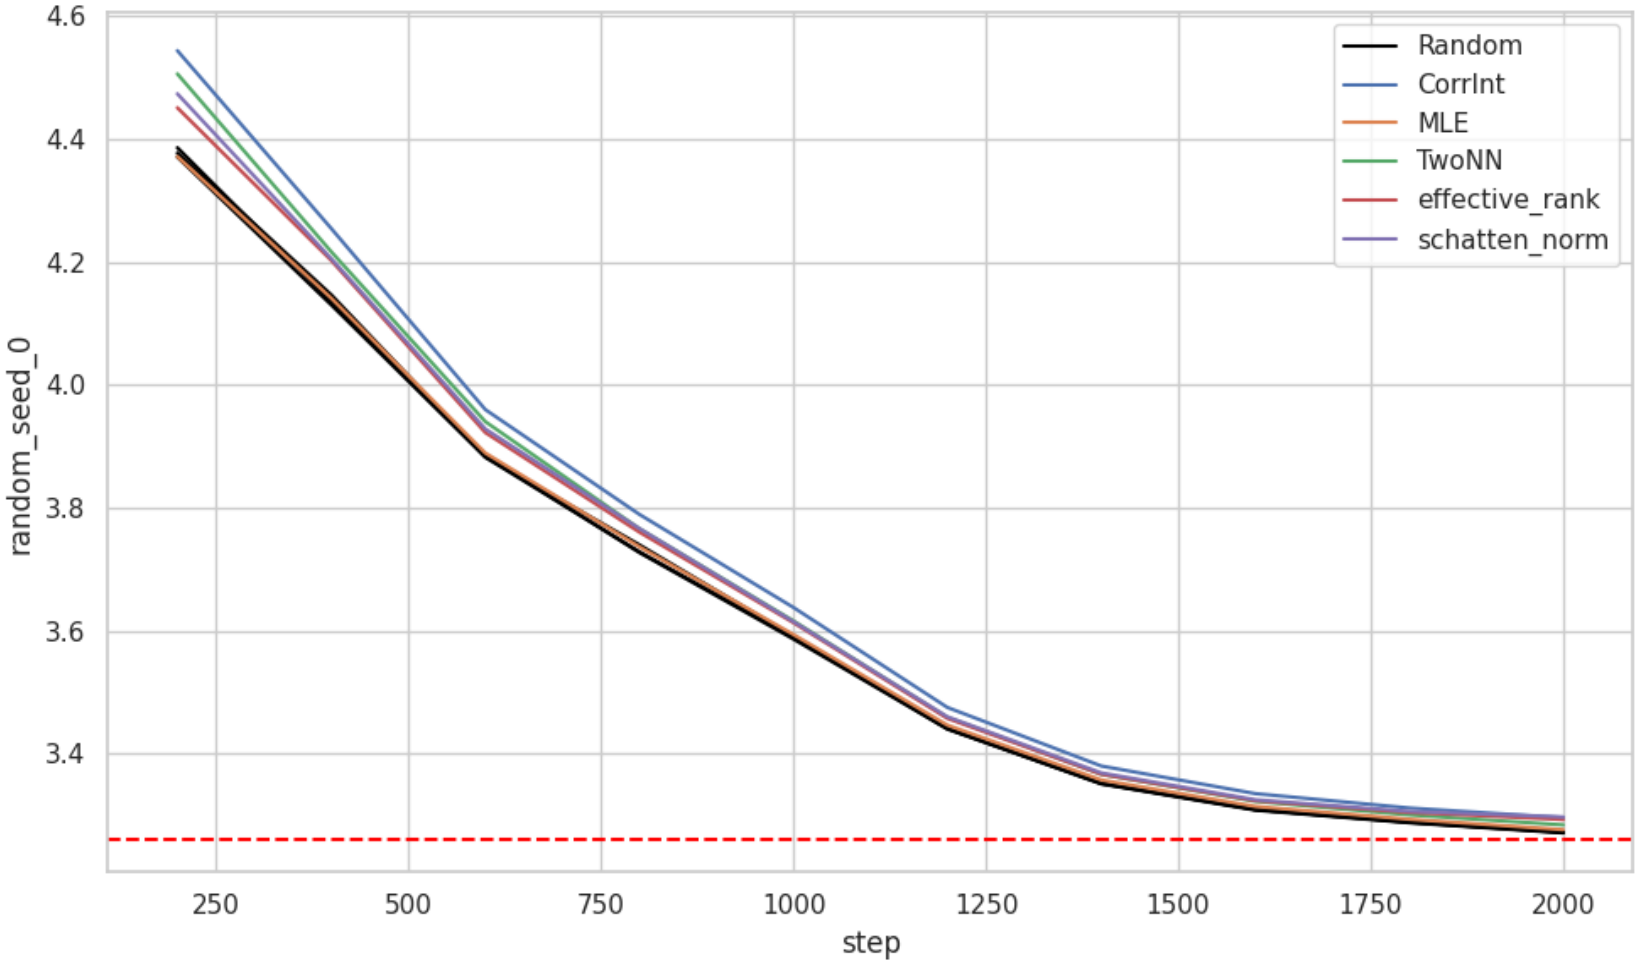
4.6
4.4
4.2
4.0
3.8
3.6
3.4
random_seed_0
250
500
750
1000
1250
1500
1750
2000
step
Random
CorrInt
MLE
TwoNN
effective_rank
schatten_norm

Выводы

Случайный отбор демонстрирует меньший loss по сравнению со всеми рассмотренными методами на всех объёмах данных.